PROJET DONNÉES MULTIMEDIA
M2 SID

Octobre-novembre 2026

Classified as Microsoft Confidential

OBJECTIFS

- Mettre en œuvre des modélisations sur :
  - Le texte
  - L'audio
  - La vidéo
- pour créer un système de reconnaissance de catégorie d'émotions dans des extraits de film
  - Amusement (amusement),
  - Awe (émerveillement),
  - Contentment (satisfaction),
  - Excitement (excitation),
  - Anger (colère),
  - Disgust (dégoût),
  - Fear (peur),
  - Sadness (tristesse)

DONNÉES (1/2)

- Sous partie du corpus EmoVid
- Documentation :
  - Corpus : https://zane-zyqiu.github.io/EmoVid/
  - Article : https://arxiv.org/pdf/2511.11002
- Seule la section « movie » a été choisie
- La quantité de données a été restreinte à 3439 extraits vidéo de 350 films
- Accès aux données pour le projet : https://filesender.renater.fr/?s=download&token=71dd5e64-4e70-42e6-a703-ea3ff0a91297

DONNÉES (2/2)

- Vidéos au format MP4 (H264 1280x720)
- Audios séparés au format MP3 (44,1 kHz, stéréo)
- Un descriptif par extrait qui résume ce qui est présent dans la scène (format JSON)


```
{
  "video_id": "00000_clip_001",
  "brightness": 0.4,
  "colorfulness": 0.3,
  "hue": 79,
  "emotion": "anger",
  "caption": "The video shows a man with red hair wearing a blue shirt, standing in front of a chain link fence. There is another man in a black beanie and white shirt standing behind him. The background includes trees and a building.",
  "duration": 5.0
}
```

TRAVAIL DEMANDÉ (1/2)

1. Se répartir en groupes de 4 personnes
2. Analyser les données fournies : voir les (dés-)équilibres, constituer un ensemble pour l'entraînement (250 films), un pour le développement (50 films) et un pour le test (50 films), en équilibrant au mieux les classes. Cette partition est a faire de manière commune pour tous les groupes d'étudiants, vous utiliserez tous les mêmes listes pour l'apprentissage, le développement et le test. Vous produirez un document de synthèse présentant ces analyses sur les données
3. Traiter les données audio pour produire des transcriptions textuelles
4. Modéliser chaque modalité (Texte, Audio et Video) de manière séparée pour obtenir un système de reconnaissance d'émotions

TRAVAIL DEMANDÉ (2/2)

5. Proposer un système qui permette de fusionner les 3 médias
6. Préparer une présentation de 20 min par groupe (chacun présente 5') qui expose les solutions mises en place pour le vendredi 6 novembre après-midi
7. Livrer un dépôt Gitlab avec un minimum de documentation sur le code

SUIVI

- Un support sur les thématiques Texte/Audio/Video va être mis en place pour voir votre avancement et répondre à vos questions (cf. créneaux sous Moodle)
- Vous pouvez également envoyer des emails sur le forum de Moodle pour poser des questions en dehors des créneaux de RDV